

OpenAI 发布自研推理芯片意味着什么

OpenAI 正式发布了首款自研芯片，代号 Jalapeño。和博通联合开发，台积电3纳米做。专做推理，不做训练。

媒体标题如果写"OpenAI发布自研芯片挑战英伟达"——这属于没看懂。

Jalapeño是推理芯片，推理芯片啊！不是训练芯片。 这是两个完全不同的市场。

训练芯片解决"怎么把模型做出来"——大规模并行计算、高带宽内存、复杂互联。这是英伟达的绝对领地，CUDA护城河在这里。

推理芯片解决"模型好了之后，每次调用怎么更便宜"——这是ASIC的强项。不需要CUDA，不需要复杂互联，只要把特定模型的计算路径固化到硬件里，效率就能比通用GPU高几倍，有点想专款专用的意思，只有一个功能，不做大而全。

推理芯片的核心目的之一，是通过优秀的设计降低单位推理成本，同时满足特定的性能与功耗约束”

所以严格意义上来说，Jalapeño是在切英伟达不太在意的那块蛋糕。英伟达的利润大头在训练卡，推理端单价低、毛利率薄。OpenAI从这里切入，是聪明打法。

几个值得关注的点

第一，9个月流片。

以前做芯片2-3年，现在9个月出来。说明三件事：AI辅助芯片设计在加速（有点机器人设计自己的意思了，准备好迎接黑客帝国吧 哈哈），博通的ASIC平台成熟度在提升，定制芯片的门槛在下降。如果越来越多大客户发现"定制芯片的成本和时间都能接受了"，通用GPU的溢价空间就会被压缩。

第二，推理成本降低约50%。

这是他们公开的数据。如果兑现，意味着调用同样模型的成本减半。对整个AI应用生态是利好——更便宜的推理=更多的应用场景=更大的总需求。但同时也意味着，靠卖推理算力赚钱的生意，毛利率会承压。当然，这也标志着AI，已经从训练转向到了推理。未来更长的上下文，更多的掉用本质上都是在用推理的能力，所以黄某认为这是一个标志性节点。

第三，2029年目标10GW。


这个数字其实很有意思。OpenAI不只是做一颗芯片，它在规划完整的算力基础设施。10GW差不多是当前全球AI数据中心总算力的好几倍。说明它们对推理需求的长期增长极度乐观。

跟昨天英伟达那件事连起来看

昨天聊英伟达搞四合一：卖设备+帮融资+建工厂+抽流水。核心是想通过资本和生态深度绑定客户。

今天OpenAI这个动作，就是客户对这套模式的**反向回应**——“你越绑定我，我越要自己搞。”

这两件事放在一起，“加盟商”和“独立站”的PK正式开打！ 下面更像是AI产业现在的真实图景：



阵营	代表	策略
自研派	OpenAI、Anthropic、苹果	推理自己做，训练暂时还用英伟达
两条腿派	Meta、微软、谷歌	采购照常，自研芯片同步推进
加盟派	中小AI公司	买不起也做不起，加入英伟达融资体系

谁受益

博通。不管谁做定制芯片，都需要设计服务。Jalapeño证明了博通在AI ASIC领域的交付能力。后续会有更多客户愿意找它做。

台积电。不管英伟达的卡还是OpenAI的芯片，都是台积电造。这个位置不变。

Celestica。系统集成商，负责把芯片变成可部署的服务器。Jalapeño的量产需要它。

谁承压

英伟达的推理份额，（注意，是推理份额）长期承压。不是说英伟达会输，而是推理市场的蛋糕会被ASIC切走一大块。但训练市场短期内它仍是绝对主导。关键在于，未来两年推理的占比会不会超过训练——如果会，那这个故事对英伟达的估值逻辑就有影响。

靠倒卖推理算力赚钱的二道贩子。成本端被ASIC压缩，利润空间会变薄。

这是一场另类的军备竞赛，一边是想赢家通吃的达子，一边是想摆脱达子的模型厂和云厂商，我们拭目以待。

不过短期赢家是做芯片的公司——博通、Alchip、世芯这类ASIC设计服务商。不管谁赢，都需要它们。