

Kimi K3的2.8万亿参数，是不是又弯道超车了？

2026.07.20

月之暗面发布了Kimi K3，号称2.8万亿参数。作为全球首款接近3万亿参数的大模型，是不是中国AI又一次完成了超车？

要回答这个问题，我们必须先弄清楚一件事：
一个大模型，究竟是怎么变聪明的？

一、一个大模型为什么会聪明？

用人类的认知成长来类比大模型

因素	类比	决定什么
参数与架构	大脑容量和结构	能装下多少复杂规律
训练数据	教材和阅读材料	模型学到了什么
训练算力	学习时间和练习次数	能把教材学多深
算法与工程	教学方法	同样的资源能学多快
后训练与蒸馏	名师辅导和批改	推理、编程、工具使用
推理工具与思考量	开卷考试 + 计算器	最终呈现出来的成绩

所以，一个模型最终表现出来的能力是由：

大脑容量、教材质量、练习数量、学习方法、老师指导和工具能力，共同决定的。

二、2.8万亿参数，是个什么概念？

一个参数，更像大脑中的一个微小连接，或者一个可以不断调节的旋钮。

比如骑自行车这项能力，至少包含：
怎么保持平衡，什么时候转动车把，脚应该怎样发力，身体应该向哪边倾斜，速度太快应该怎样刹车。这些能力，是大量神经连接共同形成的。

模型会写代码，分析财报，也是海量参数共同作用，形成了一套理解和判断问题的能力。

大量的微小连接连接最终生成了“认知”，连接越多，理论上能够容纳的规律越复杂。
但大脑大，但教材不好、训练不足、方法错误，也可能学不好。

三、K3有896个“专家”？

K3采用了一种混合专家架构。我们可以把它理解成一家拥有896个专业部门的超级咨询公司。每个部门之间的能力有些许交叉，当客户提出问题时，公司不会让896个部门全部开会。但是会根据当前正在处理的信息，从896个部门中挑选16个最合适的专家参与。比如：

分析财务数字时，选择一组专家。
处理代码时，再换一组专家。
理解图片时，又可能换成另一组。

K3官方公布的架构，是896个专家中，每处理一个信息单位，激活其中16个。月之暗面称，这种架构配合新的训练方法，使K3比K2将计算资源转化为模型能力的处理效率大约高了2.5倍。

为什么要这么做？省成本。如果2.8万亿参数每次都要一起调用，成本会高到离谱。

所以现在的做法是：

把整个公司的知识容量做得非常大，但每次只让少数合适的部门工作。

但是，这又产生了一个新的问题。虽然896个部门不需要同时工作，但它们必须全部随时待命。

那这就必须要探究K3背后的硬件资源了。

四、这样一个大模型，需要什么资源？

我们继续用咨询公司的例子。一家拥有896个专业部门的公司，首先需要足够大的办公楼。

在大模型里，这座办公楼就是显存（gpu内存，HBM）和高速内存（GPU内存，DDR）。

2.8万亿参数都是数字，这些数字必须被储存起来。即使使用很强的压缩技术，整个模型仍然非常庞大，不可能放在一张普通显卡里。

所以模型必须被拆开，分别装进许多张AI加速卡中（相当于896个专家分别在不同的办公大楼）。

要让他们相互高效交流，就需要：

高速互连、交换芯片、高速铜连接、光模块、光互连和网络调度系统。

除此之外，它还需要电力、散热和机房。大量加速卡同时运行，就像一座拥有大量重型机器的工厂。机器越多，消耗的电力越大，产生的热量越高。

于是背后还需要：

稳定供电、液冷系统、高密度机柜、配电设备和数据中心基础设施。

它带出来的是一整套系统：

模型存在哪里，谁负责计算，不同卡之间怎样交流，产生的热量怎样带走，整个系统怎样稳定运行。

五、Kimi可以直接下载到普通电脑里吗？

嘿嘿，想多了。开源只是代表了有下载的权限，但是普通电脑没有承载能力。
你想在你自家院子里整个摩天大楼？所以，这个开源是给云厂商，大企业用的。

****开源了，但是硬件门槛在那里摆着。**

六、为什么Athropic要起诉月之暗面

回到我们的第一部分的六个因素，关于起诉提到的蒸馏发生在第五个环节。蒸馏可以继续用学校来理解。

假设我们要培养一个学生，成为顶级医生。

正常的路径是：

让他自己读教材，自己分析病例，自己不断犯错，再花很多年逐渐总结出正确的诊断方法。

而蒸馏相当于：

让一名世界顶级医生，把几百万个病例的诊断结果、判断依据、检查顺序、治疗方案和复盘过程，全部演示给学生看。

学生不再需要把老师曾经走过的所有弯路重新走一遍。

他可以直接学习：

遇到这种问题先看什么，哪些可能性应该优先排除，什么时候调用工具，做错以后应该怎样修改。

所以，蒸馏最有价值的地方是帮助它学习：

一个顶级模型是怎样思考、怎样使用工具、怎样解决复杂任务的。（名师辅导，见效快）。

2026年2月，Anthropic公开指控Moonshot通过数百个账户，与Claude产生了超过340万次有组织的交互，重点获取Agent推理、工具调用、编程、数据分析、计算机操作和视觉能力。

如果这一指控成立，那么月之暗面相当于做了一件事：

它先造出了自己的学生，又让Claude充当老师，向学生批量演示世界上最先进的解题方法。

这能够大幅减少后训练阶段的探索时间、数据成本和试错成本。

七、蒸馏不能替代什么？K3是如何炼成的。

蒸馏可以加速学习，但不能凭空创造一个大脑。

一个学生即使拿到了学霸的所有答案，也必须具备理解答案的能力。

如果他没有基础知识，看不懂公式，无法记住前后逻辑，那么答案再多也没有意义。

对应到Kimi：

- 1、蒸馏不能替代2.8万亿参数的模型底座。
- 2、不能替代896个专家的组织 and 调度。
- 3、不能替代大规模GPU集群。
- 4、不能替代高速互连。
- 5、不能替代长文本架构。
- 6、不能替代模型稳定训练。
- 7、也不能替代推理部署和产品工程。

蒸馏能够做的是：

让一个已经拥有大脑、教材和训练条件的学生，更快地学会顶级老师已经掌握的方法。 还是那个句话，名师辅导，见效快。

八、K3是否意味着中国AI再次超车？

算，当然算。就像很多人认为电车已经领先世界了一样。
(嘿嘿，见笑了)。

K3，没有公开训练使用了多少张卡、什么型号、训练了多长时间。
也没有证明K3的所有能力都来自完全独立的原创探索。

**如果让我来形容k3的出现，更像是在创新药中通过合资公司取得了制作工艺。利用海外技术，取得了规模和成本的领先。

九、K3对AI行业最大的影响是什么？

K3真正冲击的，是模型能力的稀缺性。

过去市场认为，OpenAI和Anthropic花费巨额资金训练出的前沿能力，会形成一道非常深的护城河。后来者即使有钱，也需要重新走一遍数据采集、模型训练、失败试验和能力探索的全过程。

但蒸馏带来了一种新的可能。

最领先的公司负责花费巨额资本，发现一种新的能力。第二梯队先造出自己的模型底座，再通过大量调用和高质量数据，学习这种能力。

最后再通过工程优化，把它变成更便宜的API或者开放权重模型。(抄作业，我们是最强的)

整个过程可能形成一条新的产业链：

美国前沿模型负责探索，中国模型负责吸收、工程化、低价化和开放扩散。

这它意味着，最领先模型的优势维持时间可能越来越短。

过去一家公司可以领先一年。未来可能只能领先几个月。

模型能力逐渐从一种极其稀缺的产品，变成可以快速扩散的技术。(工业克苏鲁就是这么强劲)

十、AI行业的利润会向哪里转移？

我之前透过Gemni，gpt和grok我说模型正在同质化。未来重要的，可能是以下几个维度：

- 1、谁拥有更多用户。
- 2、谁掌握真实企业数据。
- 3、谁进入了企业的工作流程。
- 4、谁拥有开发者生态。
- 5、谁的推理成本更低。
- 6、谁能够让模型稳定完成真实任务。

模型本身可能越来越像一种基础设施。真正能够长期获得利润的，可能是模型之上的应用、Agent、企业软件和工作流。

就像操作系统非常重要，但大量商业价值最终产生在操作系统上的软件和服务中。

十一、这对算力意味着什么？

既然蒸馏可以减少训练时间，是不是意味着以后不再需要那么多GPU？

从单个追赶模型来看，蒸馏确实可以减少探索成本。别人已经找到正确答案，追赶者就不需要把所有错误路线重新尝试一遍。这可能降低获得同样能力所需要的训练算力。

但是，模型能力变便宜以后，会有更多公司训练模型，更多企业部署Agent，更多用户调用AI。

因此，最终算力需求取决于两个变量：

每次调用消耗多少算力，以及全社会一共调用多少次。

如果单次调用的成本下降一半，但调用量增长十倍，总算力需求仍然会增长五倍。

AI必然会从追以前的追更强GPU，更大的显存、更快的互连、更高的集群利用率和更低的推理成本。

十二、站在投资角度，应该怎样看？

第一，闭源模型公司的定价权可能受到压力。

如果开放模型可以在较短时间内逼近最先进模型，那么OpenAI和Anthropic很难永远依靠“模型更聪明”维持极高价格。模型能力的领先时间越短，API价格竞争就会越激烈。

第二，AI应用和Agent可能成为长期受益者。

模型越便宜，企业越愿意把AI放进产流程里，AI推理可能逐渐具备经济性。或许，软件和Agent即将迎来更大机会。

第三，HBM和高速互连的重要性可能继续提高。

像K3这样的超大MoE模型，需要把大量权重放进不同加速卡，并在不同专家之间频繁交换数据。

想要让几十张、几百张甚至几万张卡，像一台机器一样工作？那会持续提高显存、交换芯片、高速铜连接、光模块和数据中心网络的价值。

第四，电力、液冷和800V——长期间接受益

K3官方建议使用64张以上加速卡的超级节点，说明前沿模型部署正在向更大、更高密度的计算域演进。

完整的链条应该是：

模型能力提升、价格下降

→ 用户和Agent调用量增长

→ 推理集群扩张

→ 机柜功率和网络密度提高

→ HBM、互连、液冷、配电和电路保护需求增加。

最后，作为一个关注800V高压直流的中登，我认为被动元器件的基本面并没有崩坏，而800V将在2027和2028年带来业绩的提升。（个人观点，非投资建议）