端侧AI（上）——AI可否在本地跑？ 2026-10-12

2026年10月12日

假如未来AI越来越普及，人每天用AI的次数，从十几次涨到几十次、上百次，那我们手里的手机和电脑会发生什么变化？

在我眼里手机和电脑都像是一个个人小型数据中心。是电力+数据的游戏。

那未来人类所有的AI需求，是否可以在本地跑呢？

比如你让AI读一封邮件、搜一下昨天存在电脑里的资料、认一张照片、提醒你下午有个会。

这些破事儿，手机和电脑能不能干？而且更快、更省钱还保留隐私的干？

这就是今天黄某真正要研究的东西：**端侧AI**。

所以从一个投资者的角度来看，黄某只关心三件事：
1、它有没有必要存在？
2、会给现有设备带来什么改变？
3、会不会因此造出新的硬件需求？

一、AI用得多了十倍，为什么不把所有计算都留在云端？

把AI想象成一家卖智力服务的公司。这家公司有个总部，能力极强，什么难题都能解。

但每次找总部办事，都得通信、得等、还得付一笔计算费。

现在假设你我，每天只需要AI帮忙两三次——那所有事都甩给总部，问题不大。

但要是以后每天天要AI帮忙一百次，那还一样吗？。

从早期我们电话只用于短信+电话，到现在除了打电话发短信随时都在用手机的历史变迁来看，AI使用的频次增加基本确定。

有些活重。比如研究一家上市公司的商业模式，扒十年的财报，设计一整套软件系统——这种放在云端，合理。

但有些活轻得很。比如听个语音，整理几条通知，从相册里找一张照片——这些放在云端既没有效率也不经济。

所以更合理的分工是什么？

手机和电脑干自己力所能及的，云端专挑真正复杂的活。

这就跟一家公司一个道理：要是连买支笔都得总经理签字，那总经理每天光签字了。所以简单的事留在基层，复杂的事情往上推。

未来AI的计算体系，大概率也是这么个路子。

二、手机未来要干的，真的是运行一个缩小版的ChatGPT吗?

黄某觉得不是。或者说，这个理解只对了一半。

我们设想个场景——明天你要去上海出差。

你对手机说：帮我把明天的工作安排理一下，看有没有空约两个朋友吃饭，再把相关资料准备好。

要办成这件事，手机得知道什么?

首先得翻你的日历、相关邮件、联系人，还有你自己存在手机里的资料。

它还得听懂你说的"两个朋友"，到底是哪两个。

要再进一步检查机票时间，发消息，它还得有操作那些软件的权限。

这里面更关键的是——**AI必须能在你授权的范围内，读懂你的个人环境、拿到相关信息，然后真的去调用工具。**

有些环节可以本地做，有些复杂任务还是得喊云端模型。

所以端侧AI本质上是三种能力的组合：

1. **本地计算能力**——语音识别、信息提取、简单理解、部分推理。
2. **个人上下文管理能力**——让AI知道当前任务需要你哪条信息，尽量少传数据。
3. **系统调度与执行能力**——决定什么时候用哪个模型、什么时候要你点头、什么时候能直接调用应用把事办了。

这三样凑齐了，手机才真正意义上变成一个智能助手。

当然，云端也能干这些。但是：

谁管着你的授权关系？谁负责管你的个人上下文？谁决定最后用哪个模型？谁保证这事干得安全?

这个问题，已经超出能力范围了，它开始动到操作系统那一层。

未来端侧AI最值钱的部分，大概是**把模型变成操作系统随时能调用的能力**。

三、苹果、谷歌、微软，巨头进展如何?

2026年6月，苹果公开了第三代 Apple Foundation Models。

苹果已经正式把模型做成了**本地+云端两套配合的体系**：

- 本地：约30亿参数的基础模型，加上一套总规模200亿参数、但每次只激活一部分的稀疏模型。
- 云端：扛更复杂的推理、图片生成、智能体任务。

（俺准备找个时间去趟香港，整个港版的回来，试试看）

你可以把"参数"理解成一本超大的知识和能力手册。参数越多，手册越厚，理论上懂得越多。

传统用法是，一用模型，就得把大量相关内容塞进"快速内存"。

苹果的思路大概是：把完整模型权重放在闪存里，按任务需要只加载一部分。这样能降低模型对运行内存的即时占用，但也对调度、存储读取、内存管理提出了更高要求。

在一个空间、算力、电力、散热都不富裕的手机上，必须要靠更聪明的算法+计算架构才能让AI更进一步。

再看谷歌。

2026年，谷歌已经给Android开发者提供了本地 Gemini Nano 和云端模型之间的混合推理接口——开发者可以先走本地，设备扛不住再切云端。当时还在逐步开放和完善，但方向已经很清楚了：让开发者不用自己操心底层那些计算细节，也能搭出本地+云端协同的AI应用。

微软呢，在PC端搞了个 Copilot+ PC 标准。其中一个硬要求，是设备得有至少40 TOPS级别的专用AI算力。

TOPS 你也不用记，就理解成"芯片每秒理论上能跑多少次特定运算"。但它不是模型实际跑得快慢的全部答案——就像一辆车发动机马力很大，不代表它在所有路上都开得最快。内存、软件适配、功耗、散热，样样都会影响最终体验。

虽然苹果、谷歌、微软，三条路不一样，但都在验证同一件事：

端侧AI它正在往操作系统、应用、计算资源管理层里钻。

至少从巨头的视角看来，端侧AI已经是一场新的军备竞赛了。不过，到底能创造多大的用户价值，还有待验证

四、手机要扛更多AI，到底要升级哪些硬件?

一台手机，本质也是一个小型数据中心。但是手机的体积、电池、散热空间，基本是焊死的。

所以手机端侧AI的核心目标，应该是——**用有限的电，干更多的有效计算。**（俗称低功耗，这TM不就是高通一直在干的事吗？俺已经在高通里了，非投资建议）

硬件	生活类比	端侧AI推着它往哪走
处理器	干活的人	CPU/NPU/GPU 要更能算，更关键是"每瓦性能"——干同样的活少耗电
内存（DRA…	办公桌	模型运行时要把权重摊到桌面上用，容量和带宽都可能成为约束
存储（NAN…	文件柜	本地模型、个人数据索引都存这儿，读取性能变得更重要
供电	心脏供血	AI负载忽高忽低，电源管理、电感、电容都要跟着调
散热	空调	算得越快越烫，封装和均热得同步跟上

处理器。 过去的手机芯片里已经有 CPU、GPU、NPU 这些模块——CPU干通用活，GPU擅长并行，NPU专为部分AI运算设计。未来AI任务多了，处理器不光要更能算，更要"每瓦性能"高。低功耗X2.

内存。 这里得先分清两个东西：运行内存（DRAM）是办公桌，闪存（NAND）是文件柜。文件柜能放很多资料，但办公时得把资料拿到桌面上，才能随手用。

AI模型也一样。一个70亿参数的模型，按4-bit量化，光存模型权重理论上就要约3.5GB，真跑起来还得加缓存、运行环境、系统资源。所以内存容量和带宽，可能成为约束。

但注意，这**不代表手机必须无限加内存**。如果模型压缩效率上去了，或者能按需加载权重，同样的活可能用更少的运行内存。

存储。 端侧AI要存本地模型、个人数据索引、各种应用文件。要是系统老得从闪存里读模型再往内存里搬，那存储性能和数据管理就越来越重要。

供电。 芯片算的时候要稳定、低损耗的电。AI让计算负载忽高忽低，电源管理芯片、电感、电容、整个供电系统都得配合。但这**不意味着每台手机一定用更多颗电感**——也可能是元件变得更高效、更小型化，或者部分功能被集成进去。黄某要研究的是"单机价值量"，不是想当然猜元件数量涨没涨。

散热。 2026年9月，苹果发了 iPhone 18 Pro，用上2纳米的 A20 Pro。按苹果公开资料，比上一代内存带宽提高50%、AI算力提高，芯片封装和均热板也重新设计了。这些升级既服务AI，也服务游戏、摄影这些高性能场景。

只要性能上来，散热，功耗，内存，供电系统全部跟着升级。

五、PC可能比手机更早形成真实需求?

手机更像是个人信息消费空间，但是PC天生就具备生产力。

写程序、剪视频、分析数据、一次处理几十份文档，这些都是在电脑上发生的。
而且电脑机身大、散热宽裕、内存也能配得更大。（比如黄某的16寸 macpro，安利一下，买电脑还得苹果。）

基于功能性导致不同的付费意愿。

手机上的AI如果只是帮你理几条通知，用户未必愿意多掏一千块买新机。但一家企业要能在本地跑AI，帮员工检索内部资料、写代码、处理文档，同时少传敏感数据——那升级设备对应的，是明确的生产力收益。

所以我的判断是，pc在未来2年可能会证明其价值，但是手机更像是一个中远期期权。

六、AI不一定带来"换机潮"?

前文讲到，手机本身不是生产力，虽然**AI使用量在涨，不等于硬件需求同比例涨。**

这里头有三个变量。

第一个，新增任务量。 人用AI越多，会冒出新算力需求。

第二个，算法效率。 假设过去干一个活要十次计算，未来靠模型压缩和优化，只要两次——那单位任务的资源消耗就掉了。

第三个，现有硬件还剩多少余量。 比如现在一部手机能稳定供出"十单位"算力，而未来某项AI功能只要"五单位"，那用户根本不用换手机，软件更新一下就能用上。

只有当新任务**超过**旧设备在性能、内存、功耗、散热上的实际能力，而且这个差距对用户足够重要时，才可能推动主动换机。

再往前想一步。

假如未来AI模型越来越高效，普通手机也能跑今天高端机才能跑的模型——那端侧AI可能飞快普及，但硬件升级的幅度，反而没想象中那么大。

AI使用量、实际计算负载、新增硬件需求——这是**三件不同的事**！

七、用户、模型厂、硬件厂都愿意干，这门生意就一定成立吗?

还不一定。

先看**用户**。用户愿意为更快的响应、更好的隐私、以及真能帮自己干活的AI掏钱。但用户**不会**因为云厂省了计算成本，就主动去买更贵的手机。除非端侧AI可以带来超过成本的正向受益，否则仍然是消费而非投资生产。

再看**模型厂**。模型厂希望把那些重复、低价值的云端计算甩出去，把贵的服务器资源留给复杂任务。可要是简单任务都在本地干了，一部分原本收费的云端调用，也可能被替代。它得在"省成本、丢收入、扩用户"三者之间权衡。

最后看**硬件厂**。AI要是能抬手机售价、推动用户买高端机、或者加高用户对品牌生态的依赖，硬件厂当然有动力投。但问题是：硬件厂得**提前**掏芯片、内存、散热、系统研发的成本；而模型厂省下的云端计算费，可不会自动流进硬件厂的利润表。

产业链整体在省钱，不代表掏钱投入的那家企业一定赚钱。

八、到2026年10月，我们到底证明了什么，还没证明什么？

已经证明的三件事：

1. **端侧AI有明确的技术价值。** 低延迟、部分隐私任务、离线能力、系统协同，都让本地计算有实实在在存在的理由。
2. **端云混合已经进了商业产品和开发工具。** 苹果、谷歌、微软的实际推进，给这条路提供了证据。
3. **硬件升级已经在发生。** 先进处理器、内存带宽、封装、散热、系统调度，都在往前走。

但这三件事，只能证明**产业方向**。它们还证明不了另外三件更要命的事：

- 用户会不会因为AI主动换设备？
- 每台设备里芯片、内存、元器件的价值量，究竟会增加多少？
- 新增的收入和利润，最后被哪些企业拿走？

> **端侧AI有较高的"技术能见度"，但端侧硬件的"投资能见度"，目前还没到同样的水平。**

那么问题来了：

谁在这场竞争里拿到了定价权？谁正在赚钱，谁又在扛成本？等供给紧缺缓解了，那些看着漂亮的利润，还能留下多少？

这些问题，黄某放到下篇，继续从买方视角分析。